OLIST E-COMMERCE ANALYTICS

Project Documentation

Data Preparation • SQL Analysis • Power BI Dashboard

Project type: E-commerce Business Intelligence & Data Analytics

Primary tools: MySQL / SQL and Microsoft Power BI

Dashboard pages: 6

Documentation scope: Data Quality, Metric Definitions, Dashboard Analysis, Insights, and Assumptions

Table of Contents

1. Project Overview 3
   Project Scope 3
   Tools & Technologies 3
   Analytical Workflow 3
2. Business Objectives 3
   Business Perspective 4
3. Data Sources & Data Model 4
   Core Tables 4
   Key Relationships 5
   Grain Considerations 5
4. Data Cleaning & Validation 5
   Cleaning Principles 5
   Cleaned Views 6
   Validation Findings 6
   Business Rules 6
5. Metric Definitions 6
   5.1 Executive Overview 6
   5.2 Sales & Product 7
   5.3 Customer Performance 8
   5.4 Delivery & Operations 8
   5.5 Seller Performance 9
   5.6 Review & Customer Satisfaction 10
   Metric Consistency Rules 10
6. Dashboard Page Overview 10
7. Key Findings / Insights 11
   Recommendations 11
8. Limitations & Interpretation 12
   Overall Interpretation 12

1. Project Overview

Olist E-Commerce Analytics merupakan project business intelligence dan data analytics yang bertujuan untuk menganalisis data transaksi e-commerce guna mengevaluasi kinerja bisnis dan customer experience. Project ini menggunakan SQL untuk melakukan data validation, data quality assessment, dan data cleaning, kemudian dilanjutkan dengan data modeling dan analisis menggunakan Microsoft Power BI. Output akhir project berupa interactive six-page Power BI dashboard yang mencakup analisis Sales and Product Performance, Customer Performance, Delivery and Operations, Seller Performance, serta Customer Satisfaction.

Project Scope

- Menganalisis kinerja dan tren penjualan e-commerce secara keseluruhan.
- Mengevaluasi kinerja kategori produk.
- Memahami kontribusi pelanggan dan purchasing behavior.
- Mengevaluasi delivery performance dan operational outcomes.
- Mengevaluasi seller performance dan kontribusi Product Sales.
- Menganalisis customer reviews dan customer satisfaction, termasuk keterkaitannya dengan delivery performance.

Tools & Technologies

Tool	Purpose
MySQL / SQL	Melakukan data import, data validation, data quality checks, data cleaning logic, dan analytical queries.
Microsoft Power BI	Melakukan data modeling, pembuatan DAX measures, interactive visualizations, slicers, dan dashboard development.
Microsoft Excel	Mendukung proses data inspection, validation, dan analytical checks.

Analytical Workflow

1. Melakukan import dan inspection terhadap source data.
2. Melakukan data quality checks dan mengidentifikasi data anomalies.
3. Menerapkan cleaning logic melalui SQL views dengan tetap mempertahankan raw tables.
4. Membangun data model, relationships, dan analytical measures di Power BI.
5. Melakukan validasi terhadap KPI calculations, filter behavior, dan visual interactions.
6. Merancang enam dashboard pages berdasarkan business questions yang berbeda.
7. Merumuskan key findings serta mendokumentasikan assumptions, limitations, dan data considerations.

2. Business Objectives

Dashboard dirancang untuk menjawab beberapa business questions berikut:

- Bagaimana overall sales performance berubah dari waktu ke waktu?
- Produk dan kategori mana yang memberikan kontribusi terbesar terhadap Product Sales dan item activity?

- Berapa banyak active customers, dan berapa besar Payment Value yang mereka kontribusikan?
- Seberapa efektif orders dikirim tepat waktu, dan di area mana delivery issues terjadi?
- Seller mana yang active dan menghasilkan Product Sales terbesar?
- Bagaimana delivery performance dan customer review scores dibandingkan antara On-Time dan Late deliveries?
- Customer states mana yang menunjukkan customer satisfaction yang lebih tinggi atau lebih rendah?
- Area mana yang perlu ditindaklanjuti oleh management untuk commercial, operational, atau customer experience improvement?

Business Perspective

Setiap dashboard page memiliki analytical focus yang jelas untuk memastikan bahwa financial, customer, operational, seller, dan customer satisfaction metrics disajikan sesuai dengan konteks bisnis yang relevan. Dashboard menggunakan pendekatan data storytelling, dengan alur analisis yang bergerak dari gambaran high-level business performance menuju analisis yang lebih detail serta area yang berpotensi untuk ditindaklanjuti.

3. Data Sources & Data Model

Project ini menggunakan Olist Brazilian e-commerce dataset, yaitu relational dataset yang berisi informasi mengenai customers, orders, order items, payments, reviews, products, sellers, dan geographic references. Data dipersiapkan dan divalidasi menggunakan SQL, dengan cleaned views yang digunakan sebagai sumber analisis sementara raw tables tetap dipertahankan.

Core Tables

Table	Analytical Role
customers	Data mengenai customer identity dan location, termasuk customer_unique_id dan customer_state.
orders_clean	Data order status dan order lifecycle timestamps yang telah melalui proses cleaning, digunakan untuk menganalisis order fulfillment dan delivery performance.
order_items	Data transaksi pada tingkat order-item, termasuk order_id, product_id, seller_id, dan price, yang digunakan untuk product dan seller analysis.
order_payments	Data transaksi pada tingkat payment, termasuk payment_value, yang digunakan untuk payment-based financial analysis.
order_reviews_clean	Data customer review yang telah melalui proses cleaning, termasuk review scores dan review-related timestamps.
products_clean	Data product attributes dan product category information yang telah melalui proses cleaning, digunakan untuk product dan category analysis.
sellers	Seller master data, termasuk seller_id dan seller_state, yang digunakan untuk seller performance dan geographic analysis.
geolocation	Geographic reference data yang berisi informasi lokasi dan akan digunakan jika diperlukan untuk geographic analysis.

Key Relationships

- customers → orders_clean melalui customer_id.
- orders_clean → order_items melalui order_id.
- orders_clean → order_payments melalui order_id.
- orders_clean → order_reviews_clean melalui order_id.
- products_clean → order_items melalui product_id.
- sellers → order_items melalui seller_id.

Note: Relationship order_id antara orders_clean dan order_reviews_clean menunjukkan hubungan logis antara orders dan review records. Data review tidak dapat diasumsikan memiliki hubungan one-to-one secara ketat dengan orders maupun individual product items.

Grain Considerations

- orders_clean merupakan order-level table, di mana setiap record merepresentasikan satu order.
- order_items merupakan order-item-level table; satu order dapat memiliki beberapa items dan beberapa sellers.
- order_payments merupakan payment-level table; satu order dapat memiliki beberapa payment records.
- order_reviews_clean merupakan review-record-level table dan tidak dapat diinterpretasikan sebagai satu row untuk setiap product item atau sebagai tabel dengan satu row untuk setiap order secara ketat.
- Seller-level order counts menggunakan distinct order_id untuk setiap seller, bukan menghitung jumlah rows pada order_items.
- Product dan seller analysis dilakukan pada grain order_items, sedangkan order-level metrics menggunakan distinct order_id sesuai kebutuhan analisis.

4. Data Cleaning & Validation

Data preparation dilakukan sebelum dashboard analysis untuk meningkatkan konsistensi data, mengidentifikasi data quality issues, serta mencegah source-data anomalies yang telah diketahui agar tidak diinterpretasikan sebagai business events yang valid. Raw tables tetap dipertahankan, sementara cleaning logic diterapkan melalui SQL views yang digunakan sebagai analytical sources.

Cleaning Principles

- Raw source tables tetap dipertahankan dan tidak dimodifikasi secara langsung.
- Blank strings dinormalisasi menjadi NULL jika sesuai dengan konteks data.
- Zero datetime values dinormalisasi menjadi NULL ketika merepresentasikan missing timestamps.
- Numeric zero values yang berasal dari empty CSV fields ditinjau dan dinormalisasi menjadi NULL jika sesuai dengan konteks data.
- Known anomalies yang tidak dapat dikoreksi secara aman tetap dipertahankan dan didokumentasikan, bukan diubah secara sembarangan tanpa dasar data yang valid.

Cleaned Views

View	Purpose
orders_clean	Menyediakan order data dengan missing datetime values yang telah dinormalisasi menjadi NULL.
order_reviews_clean	Menyediakan review data dengan blank title/message fields dan invalid zero timestamps yang telah dinormalisasi.
products_clean	Menyediakan product data dengan blank category values serta invalid zero dimensions/measurements yang telah dinormalisasi.

Validation Findings

- Delivery classification mengidentifikasi 88.644 On-Time delivered orders, 7.826 Late delivered orders, dan 8 Unknown delivered orders. Selain itu, terdapat 2.963 Not Delivered orders.
- 8 Unknown delivered records memiliki actual delivery dates yang missing, sementara estimated delivery dates tersedia.
- Review table mengandung duplicate review records dan review IDs yang terkait dengan lebih dari satu order.
- Beberapa payment records memiliki payment_value = 0 atau payment_installments = 0 dan memerlukan business-rule handling secara eksplisit.
- Ditemukan timestamp anomalies, termasuk kasus ketika Approved > Carrier atau Carrier > Customer.
- 13 product categories tidak memiliki translated English category names pada source data.

Business Rules

- Product, category, item, dan seller metrics menggunakan order_items dengan price > 0 ketika metric merepresentasikan valid product activity.
- Payment-level financial metrics menggunakan order_payments dengan payment_value > 0.
- Delivered-only analyses menggunakan order_status = 'delivered'.
- Delivery-performance comparisons mengecualikan record Unknown dan Not Delivered ketika analisis membutuhkan delivery outcome yang valid.

5. Metric Definitions

Metrics didefinisikan berdasarkan analytical grain, business purpose, dan business rules yang berlaku. Filter dan data-validity criteria yang konsisten diterapkan pada setiap analytical context untuk memastikan bahwa KPI dihitung secara tepat dan tetap konsisten pada analisis yang saling berkaitan.

5.1 Executive Overview

Metric	Business Definition	Calculation / Logic	Filter / Scope
Product Sales Value	Total nilai product sales yang dihasilkan dari valid delivered product sales.	SUM(order_items[price])	Delivered; price > 0
Total Orders	Jumlah unique orders dalam report filter context yang dipilih.	DISTINCTCOUNT(order_id)	Report filter context

Average Product Sales Per Order	Rata-rata Product Sales yang dihasilkan per qualifying delivered order.	Product Sales Value ÷ Total Delivered Orders (Product)	Delivered; price > 0
Active Customers	Jumlah distinct customers yang memiliki qualifying delivered orders.	DISTINCTCOUNT(customer_unique_id)	Delivered; valid payment orders
Repeat Customer Rate	Persentase active customers yang melakukan minimal dua distinct financially valid delivered orders.	Total Repeat Customers ÷ Active Customers	Delivered; valid payment orders dengan payment_value > 0
Average Review Score	Rata-rata review score customer pada review population yang dianalisis.	AVERAGE(review_score)	Delivered
On-Time Delivery Rate	Persentase delivered orders dengan delivery outcome yang diketahui dan diterima pada atau sebelum estimated delivery date.	On-Time Delivered Orders ÷ Known Delivery Outcome Orders	Delivered; mengecualikan Unknown delivery outcomes
Cancellation Rate	Persentase orders yang berstatus cancelled dalam order population yang dipilih.	Cancelled Orders ÷ Total Orders (All Statuses)	Berdasarkan report filter context

5.2 Sales & Product

Metric	Business Definition	Calculation / Logic	Filter / Scope
Product Sales Value	Total nilai product sales yang dihasilkan dari valid delivered product sales.	SUM(order_items[price])	Delivered; price > 0
Delivered Orders	Total Delivered Orders (Product). Jumlah unique orders yang berhasil delivered.	DISTINCTCOUNT(order_id)	Delivered; price > 0
Average Product Sales per Order	Rata-rata Product Sales yang dihasilkan per qualifying delivered order.	Product Sales Value ÷ Total Delivered Orders (Product)	Delivered; price > 0
Items Sold	Jumlah seluruh valid product items yang terdapat dalam delivered orders.	COUNT(order_item_id)	Delivered; price > 0
Average Product Price	Rata-rata harga per valid product item yang terdapat dalam delivered orders.	Product Sales Value ÷ Total Product Sales across all product categories	Delivered; price > 0

Product Sales Contribution	Persentase kontribusi product category yang dipilih terhadap total Product Sales seluruh product categories dalam report context yang sedang berlaku.	Category Product Sales ÷ Total Product Sales	Delivered; price > 0
Average Review Score	Rata-rata review score customer yang terkait dengan produk pada masing-masing product category.	AVERAGE(review_score)	Delivered; review population sesuai selected product/category context

5.3 Customer Performance

Metric	Business Definition	Calculation / Logic	Filter / Scope
Active Customers	Jumlah distinct customers yang memiliki financially valid delivered orders.	DISTINCTCOUNT(customer_unique_id) berdasarkan valid orders	Delivered; payment_value > 0
Average Spend per Customer	Rata-rata Payment Value yang dihasilkan per active customer dalam selected report context.	Total Payment Value ÷ Active Customers	Delivered; payment_value > 0
Average Orders per Customer	Rata-rata jumlah financially valid delivered orders yang dilakukan oleh setiap active customer.	Total Delivered Orders (Financial) ÷ Active Customers (Financial)	Delivered; payment_value > 0
Average Items per Order	Rata-rata jumlah valid product items yang terdapat dalam financially valid delivered orders.	Total Items Sold (Financial) ÷ Total Delivered Orders (Financial)	Delivered; payment_value > 0; price > 0
Repeat Customer Rate	Persentase active customers yang melakukan minimal dua distinct financially valid delivered orders.	Total Repeat Customers ÷ Active Customers (Financial)	Delivered; payment_value > 0
Total Repeat Customers	Jumlah active customers yang melakukan minimal dua distinct financially valid delivered orders.	Count customers dengan DISTINCTCOUNT(order_id) >= 2	Delivered; payment_value > 0
Total One-Time Customers	Jumlah active customers yang hanya melakukan satu distinct financially valid delivered order.	Count customers dengan DISTINCTCOUNT(order_id) = 1	Delivered; payment_value > 0

5.4 Delivery & Operations

Metric	Business Definition	Calculation / Logic	Filter / Scope
Total Delivered Orders	Jumlah unique orders yang berhasil delivered.	DISTINCTCOUNT(order_id)	Delivered
On-Time Delivered Orders	Jumlah delivered orders yang diterima pada atau sebelum estimated delivery date.	DISTINCTCOUNT(order_id) dengan actual delivery date ≤ estimated delivery date	Delivered; actual dan estimated delivery dates valid

Late Delivered Orders	Jumlah delivered orders yang diterima setelah estimated delivery date.	DISTINCTCOUNT(order_id) dengan actual delivery date > estimated delivery date	Delivered; actual dan estimated delivery dates valid
On-Time Delivery Rate	Persentase delivered orders dengan delivery outcome yang diketahui dan diterima pada atau sebelum estimated delivery date.	On-Time Delivered Orders ÷ Known Delivery Outcome Orders	Delivered; mengecualikan Unknown delivery outcomes
Late Delivery Rate	Persentase delivered orders dengan delivery outcome yang diketahui dan diterima setelah estimated delivery date.	Late Delivered Orders ÷ Known Delivery Outcome Orders	Delivered; mengecualikan Unknown delivery outcomes
Average Delivery Delay (Days)	Rata-rata jumlah hari keterlambatan delivered orders dibandingkan dengan estimated delivery date.	Average delivery delay untuk late deliveries	Delivered; late orders dengan delivery dates valid
Avg Review Score	Rata-rata review score customer yang terkait dengan delivered orders pada masing-masing customer state.	AVERAGE(review_score)	Delivered review population; grouped by customer_state

5.5 Seller Performance

Metric	Business Definition	Calculation / Logic	Filter / Scope
Total Sellers	Jumlah distinct sellers yang tersedia dalam dataset.	DISTINCTCOUNT(seller_id)	Current report context
Active Sellers	Jumlah distinct sellers yang terkait dengan delivered orders.	DISTINCTCOUNT(seller_id)	Delivered orders
Average Product Sales per Seller	Rata-rata Product Sales yang dihasilkan oleh setiap active seller.	Total Seller Product Sales ÷ Active Sellers	Delivered; valid product sales (price > 0)
Average Orders per Seller	Rata-rata jumlah distinct delivered orders yang terkait dengan setiap active seller.	Rata-rata distinct delivered orders pada tingkat seller	Delivered; price >0
Delivered Orders by Seller	Jumlah distinct delivered orders yang terkait dengan masing-masing seller.	DISTINCTCOUNT(order_id)	Delivered; price >0; grouped by seller
Items Sold by Seller	Jumlah valid product items yang terjual oleh masing-masing seller melalui delivered orders.	COUNT(order_item_id)	Delivered; price > 0; grouped by seller
Average Review Score by Seller	Rata-rata review score customer yang terkait dengan masing-masing seller.	AVERAGE(review_score)	Review population yang terkait dengan seller
Seller Product Sales by State	Total Product Sales yang terkait dengan seller pada masing-masing seller state.	SUM(order_items[price])	Delivered; price > 0; grouped by seller_state

5.6 Review & Customer Satisfaction

Metric	Business Definition	Calculation / Logic	Filter / Scope
Average Review Score	Rata-rata review score customer dalam current report context.	Average review_score	Review population dalam current report context
Total Reviews	Jumlah review records yang digunakan dalam analisis.	Count review records	Current report context
Positive Review Rate	Persentase review records yang diklasifikasikan sebagai positive berdasarkan sentiment classification rule yang digunakan dalam project.	Positive Reviews ÷ Total Reviews	Current report context
Negative Review Rate	Persentase review records yang diklasifikasikan sebagai negative berdasarkan sentiment classification rule yang digunakan dalam project.	Negative Reviews ÷ Total Reviews	Current report context
Customer Satisfaction Trend	Rata-rata customer review score pada setiap periode waktu yang dipilih.	Average review_score per period	Current report context; grouped by order date
Satisfaction Score: On-Time vs Late	Rata-rata review score yang terkait dengan On-Time dan Late delivered orders.	Average review_score berdasarkan delivery outcome	Delivered orders dengan known delivery outcome
Review Count by Rating	Jumlah review records untuk setiap rating dari 1 hingga 5 stars.	Count review records berdasarkan review_score	Current report context; grouped by rating

Metric Consistency Rules

- Seller, product, dan item metrics menggunakan price > 0 ketika metric merepresentasikan valid product activity.
- Payment-level metrics menggunakan payment_value > 0 untuk mengidentifikasi payment transactions yang valid secara finansial.
- Delivered-only metrics menggunakan order_status = 'delivered'.
- Average Orders per Seller menggunakan distinct order_id pada masing-masing seller karena satu order dapat memiliki beberapa items dan sellers.
- Review metrics diinterpretasikan pada review-record grain dan tidak mengasumsikan bahwa satu row merepresentasikan satu unique review, order, atau product.

6. Dashboard Page Overview

Page	Focus	Primary Business Questions
1. Executive Overview	Overall business performance	Bagaimana kinerja bisnis secara keseluruhan, dan bagaimana key metrics berubah dari waktu ke waktu?

2. Sales & Product	Sales and product performance	Product categories mana yang memberikan kontribusi terbesar terhadap Product Sales dan item activity?
3. Customer Performance	Customer contribution and behavior	Siapa saja active customers, dan berapa besar Payment Value yang mereka kontribusikan?
4. Delivery & Operations	Delivery and operational performance	Seberapa efektif orders dikirim, dan di area mana delivery issues terkonsentrasi?
5. Seller Performance	Seller activity and contribution	Seller mana yang active dan memberikan kontribusi Product Sales terbesar?
6. Review & Customer Satisfaction	Customer feedback and satisfaction	Bagaimana review scores serta positive/negative sentiment bervariasi berdasarkan state dan delivery performance?

7. Key Findings / Insights

Temuan berikut merangkum major analytical themes yang diidentifikasi dari dashboard analysis dan data validation process.

- Pengiriman: 91,89% delivered orders tiba tepat waktu, sedangkan 8,11% (7.826 order) terlambat.
- Keterlambatan dan kepuasan: Skor review order terlambat 2,57, dibanding 4,29 untuk order tepat waktu. Sejak 2017, bulan dengan late rate tertinggi (Mar 2018: 21,36%) juga memiliki skor review terendah (3,81).
- Variasi antar-state: Late rate tertinggi ada di AL (23,93%) dan MA (19,67%), yang juga memiliki skor review (3,84), sedangkan SP dengan skor tertinggi (4,25). RJ memiliki order terlambat terbanyak (1.664).
- Retensi rendah: Repeat customer rate hanya 3% (97% pelanggan membeli sekali).
- Konsentrasi seller: 13 seller teratas menyumbang sekitar R$2,11 juta (±16% product sales), padahal hanya 0,4% dari 3.095 seller.
- Kategori: Health & Beauty adalah kategori terbesar (9,33%, review 4,23). Bed, Bath, Table paling banyak terjual (11,0K item) tetapi review-nya terendah di antara kategori teratas (4,00).

Recommendations

- Logistik: Prioritaskan wilayah dengan late rate tinggi (AL, MA) dan volume terlambat terbesar (RJ), serta siapkan kapasitas sebelum puncak musiman, karena late rate naik saat penjualan memuncak (Nov 2017).
- Retensi: Rancang program pembelian ulang (voucher atau email follow-up) untuk pelanggan dengan review 4-5. Sebagai gambaran dampak, setiap kenaikan 1 poin persentase repeat rate (dari 3% saat ini) setara dengan sekitar 930 (1% × 93.357) pelanggan yang kembali membeli. Pantau repeat rate setiap bulan untuk mengukur hasilnya.
- Seller: Beri eksposur kepada seller berating tinggi, yang berbeda dari seller dengan penjualan tertinggi. Tambahkan seller di luar SP untuk memperpendek jarak kirim.
- Kategori: Telusuri ulasan negatif Bed, Bath, Table untuk mencari penyebab rating 4,00.

8. Limitations & Interpretation

Area	Limitation
Order Items	order_items tidak memiliki explicit quantity column; item volume direpresentasikan oleh jumlah order-item records.
Seller Grain	Satu order dapat memiliki items dari beberapa sellers; oleh karena itu, seller order counts menggunakan distinct order_id untuk setiap seller.
Reviews	Review records tidak dapat dipastikan merepresentasikan satu unique product item atau satu unique order pada setiap row. Duplicate review records, duplicate review IDs, dan multiple order ditemukan selama validation.
Delivery Status	Delapan delivered records memiliki actual delivery dates yang missing dan diklasifikasikan sebagai Unknown untuk delivery-performance analysis.
Delivery Timestamps	Beberapa source timestamps memiliki logical anomalies, seperti Approved yang terjadi setelah Carrier atau Carrier setelah Customer.
Product Categories	Tiga belas product categories tidak memiliki translated English category names pada source data.
Transaction Validity Rule	Product Sales metrics menggunakan price > 0, sedangkan payment-level metrics menggunakan payment_value > 0 untuk mengidentifikasi transaksi yang valid dalam masing-masing analytical context.
Delivered Scope	Metrics yang secara eksplisit berlabel delivered menggunakan order_status = 'delivered'.
Customer Identity	Customer-level analysis menggunakan customer_unique_id sebagai business customer identity jika sesuai dengan analytical context.
Time Filtering	Order Date slicer dimaksudkan untuk memberikan time context yang konsisten pada dashboard pages.
Minimum-Order Threshold	Kualifikasi seller menggunakan tabel parameter terpisah; setiap measure harus menerapkan ambang batas yang dipilih secara eksplisit.
Causality	Hubungan yang teramati antara delivery performance, Product Sales, Payment Value, seller performance, dan review scores tidak boleh diinterpretasikan sebagai hubungan sebab-akibat tanpa analysis lebih lanjut.

Overall Interpretation

Dashboard ini adalah alat analisis deskriptif dan diagnostik untuk memantau kinerja, membandingkan segmen, dan mengidentifikasi area yang perlu diselidiki lebih lanjut. Analisis didasarkan pada data historis Olist periode 2016-2018, sehingga tidak dapat memprediksi kinerja masa depan. Hubungan antar-metrik, seperti keterlambatan pengiriman dan skor review, bersifat korelasi dan tidak membuktikan sebab-akibat. Dataset juga tidak memuat biaya atau margin, jadi analisis berfokus pada penjualan (product sales), bukan profitabilitas.

End of Project Documentation